

Анализ статьи "REACTION MINER: An Integrated System for Chemical Reaction Extraction from Textual Data" (EMNLP, 2023)

Ming Zhong, Siru Ouyang, Yizhu Jiao, Priyanka Kargupta, Leo Luo, Yanzhen Shen, Bobby Zhou, Xianrui Zhong, Xuan Liu, Hongxiang Li, Jinfeng Xiao, Minhao Jiang, Vivian Hu, Xuan Wang, Heng Ji, Martin Burke, Huimin Zhao, Jiawei Han

Аннотация

Chemical reactions, as a core entity in the realm of chemistry, hold crucial implications in diverse areas ranging from hands-on laboratory research to advanced computational drug design. Despite a burgeoning interest in employing NLP techniques to extract these reactions, aligning this task with the real-world requirements of chemistry practitioners remains an ongoing challenge. In this paper, we present REACTION MINER, a system specifically designed to interact with raw scientific literature, delivering precise and more informative chemical reactions. Going beyond mere extraction, REACTION MINER integrates a holistic workflow: it accepts PDF files as input, bypassing the need for pre-processing and bolstering user accessibility. Subsequently, a text segmentation module ensures that the refined text encapsulates complete chemical reactions, augmenting the accuracy of extraction. Moreover, REACTION MINER broadens the scope of existing pre-defined reaction roles, including vital attributes previously neglected, thereby offering a more comprehensive depiction of chemical reactions. Evaluations conducted by chemistry domain users highlight the efficacy of each module in our system, demonstrating REACTION MINER as a powerful tool in this field

1. Контекст и мотивация

Автоматическое извлечение информации из научной литературы — одна из ключевых задач в области NLP. В химии центральным объектом являются химические реакции: их описание необходимо для планирования синтеза, предсказания реакционной способности, разработки лекарств. Несмотря на существование отдельных инструментов (OPSIN, ChemRxnBERT, ReactIE), они не удовлетворяют реальным потребностям химиков-исследователей.

Авторы статьи выделяют четыре основных разрыва между существующими системами и требованиями пользователей:

1. **Несоответствие входного формата:** Химики работают с PDF, а не с «чистым» текстом.
2. **Ограниченная гранулярность:** Анализ на уровне предложения часто не охватывает полное описание реакции.

3. **Узкий набор извлекаемых атрибутов:** Помимо стандартных ролей (продукт, реагент, температура, выход), важны и другие детали: атмосфера, спектроскопические данные, процедура.
4. **Несогласованность выходного формата:** Некорректные символы, неполные названия затрудняют использование результатов.

Система REACTION MINER призвана устранить эти недостатки, предоставляя сквозной конвейер от PDF до структурированного описания реакции.

2. Цель статьи и основной вклад

Цель: Разработать интегрированную систему REACTION MINER, которая принимает на вход PDF, автоматически сегментирует текст, обогащает набор извлекаемых ролей и выдаёт унифицированное представление химических реакций, мак-

симально удобное для конечного пользователя-химика.

Основной вклад заключается в создании четырёх модулей, каждый из которых решает одну из описанных проблем:

1. **PDF-to-Text:** Специализированный парсер с динамической фильтрацией мусора на основе Sentence-BERT.
2. **Сегментация текста:** Поиск границ описания реакции по ключевым словам и тематической сегментации.
3. **Обогащение ролей:** Расширение набора ролей с 9 до 19 с помощью автоматического майнинга событий и генерации синтетических данных через GPT-4.
4. **Унифицированное извлечение:** Модель на базе LLaMA-7B, дообученная методом LoRA на собранном корпусе (Open Reaction Database, Reaction Corpus, GPT-4-сгенерированные данные, негативные примеры).

Каждый модуль оценивается отдельно, а итоговая система валидируется химиками-экспертами, что подтверждает её превосходство над предшественниками (ReactIE) и проприетарными LLM (GPT-4) в задачах сегментации и извлечения.

3. Сценарий использования

Система предназначена для химиков-исследователей и фармацевтических компаний. Типичный сценарий:

- Пользователь загружает PDF-файл научной статьи в веб-интерфейс или десктоп-приложение REACTION MINER.
- Система автоматически очищает текст, находит все фрагменты, описывающие химические реакции, и извлекает для каждой реакции до

19 атрибутов (продукты, реагенты, катализаторы, условия, процедуру, спектральные данные и т.д.).

- Результат выводится в структурированном формате (JSON/CSV), готовом для импорта в электронные лабораторные журналы или базы данных.

Таким образом, REACTION MINER может служить основой для автоматического пополнения баз знаний (например, Reaxys, SciFinder) или интегрироваться в платформы для ускоренного поиска химической информации.

4. Обзор литературы и место статьи

Авторы сравнивают свою систему с рядом предшествующих работ:

- **OPSIN** [1] — эвристический инструмент для извлечения структур, но не полного контекста реакций.
- **ChemRxnBERT** — модель на основе BERT для представления реакций, но не сквозное извлечение.
- **ReactIE** [4] — предыдущая SOTA-система от части авторов (Flan-T5), работающая только с готовым текстом и ограниченным набором ролей.
- **Open Reaction Database** [2] — репозиторий реакций из патентов, размеченный правилами OPSIN (требует переработки).
- **Reaction Corpus** [3] — вручную размеченный датасет, где продукты представлены идентификаторами, а не полными названиями.
- **GPT-4 / ChatGPT** [5] — сильные проприетарные модели, но на задаче сегментации

REACTION MINER их превосходит (улучшение на 16,2% по метрике P_k), а на извлечении работает наравне при существенно меньшем размере.

Главное отличие REACTION MINER — создание законченного, ориентированного на пользователя пайплайна, охватывающего все этапы от PDF до структурированных данных, и валидация каждого шага экспертами.

5. План собственного исследования на основе статьи

Тема дипломной работы: «Разработка методов извлечения доменно-специфической информации из текстов (на примере химических свойств веществ) с использованием LLM для разметки и последующей дистилляции знаний в модель типа BERT».

Статья REACTION MINER служит отправной точкой, особенно её модуль обогащения ролей. Однако моя задача смещена с реакций на **свойства веществ** (растворимость, температура плавления, спектральные характеристики). Предлагается следующие возможные направления исследования:

5.1 Адаптация к новому домену: свойства веществ

1. Определить целевые роли для описания свойств: [Substance], [Property_Name], [Property_Value], [Conditions], [Measurement_Method].
2. Модифицировать промпт для GPT-4 (аналогично рис. 8 из статьи) так, чтобы модель генерировала короткие научные абзацы, описывающие свойства веществ (например: “*The solubility of compound X in water was determined to be 15 mg/mL at 25°C using the shake-flask method.*”).
3. Сгенерировать несколько тысяч синтетических

примеров, формируя таким образом обучающий набор для извлечения информации.

5.2 Дистилляция знаний в компактную модель(основной пункт)

В REACTION MINER финальный экстрактор — LLaMA-7B (7 млрд параметров). Моё улучшение: заменить его лёгкой моделью на базе **BERT** (110 млн) или **DistilBERT** (66 млн). Задача формулируется как токен-классификация (NER) или span-based extraction. Это позволит создать быстрый, автономный инструмент, не требующий обращения к API или мощным GPU.

5.3 Ablation study (анализ влияния компонентов)

Планируется серия экспериментов:

- Сравнение качества при обучении только на реальном небольшом корпусе против обучения на смеси с синтетическими данными.
- Определение оптимального объёма синтетических примеров.
- Сравнение разных предобученных моделей: BioBERT, SciBERT, обычный BERT-base.
- Оценка вклада дополнительных ролей (Conditions, Method) в точность извлечения значений свойств.

5.4 Анализ ошибок

Ручной анализ случаев, где BERT ошибается: сложные химические названия, неоднозначность контекста, некорректная генерация GPT-4. Это позволит наметить пути дальнейшего улучшения (например, использование словарей или правил постобработки).

Таблица 1: Расширенный набор ролей химических реакций (по материалам статьи)

Роль	Описание
<i>Стандартные роли (9)</i>	
Product	Конечный продукт реакции
Reactant	Вещество, поставляющее тяжёлые атомы в продукт
Catalyst	Катализатор
Solvent	Растворитель
Time	Продолжительность реакции
Temperature	Температура
Yield	Выход продукта
Reaction type	Тип реакции
Workup reagents	Реагенты для выделения продукта
<i>Новые роли (10)</i>	
Atmosphere	Газовая атмосфера (азот, аргон и т.п.)
Inhibitor	Ингибитор
Pressure	Давление
pH	pH среды
Speed	Скорость перемешивания
Vacuum condition	Условия вакуума
Light condition	Условия освещения (для фотохимии)
Cooling/Heating Condition	Режим нагрева/охлаждения
Spectroscopic data	Спектроскопические данные
Procedure	Детальная процедура

5.5 Практическая реализация и демо

Результатом станет веб-демо (Streamlit / Gradio), где пользователь может вставить абзац текста и получить подсвеченные сущности (вещества, свойства, значения) и структурированную таблицу. Демо подчеркнёт преимущества легковесной модели: скорость работы, локальное исполнение, конфиденциальность данных.

Список литературы

- [1] Lowe, D. M. (2012). Extraction of chemical structures and reactions from the literature. PhD thesis, University of Cambridge.
- [2] Lowe, D. (2018). Chemical reactions from US patents (1976–Sep2016). Figshare. doi:10.6084/m9.figshare.5104873.
- [3] Guo, J., Ibanez-Lopez, A. S., Gao, H. et al. (2022). Automated chemical reaction extraction from scientific literature. *Journal of Chemical Information and Modeling*, 62(9), 2035–2045.
- [4] Zhong, M. et al. (2023). ReactIE: A system for extracting chemical reactions from text. In *Proceedings of EMNLP 2023 (System Demonstrations)*.
- [5] OpenAI (2023). GPT-4 Technical Report. *arXiv:2303.08774*.

Приложение: Пример промпта для генерации данных (адаптированный из статьи)

Please help me with a chemistry-related task which is divided into two steps: First, generate a paragraph in a scientific paper, which describes one or multiple specific property measurements of chemical compounds. Second, extract the information of all property measurements one by one from the generated paragraph. Completing these two steps generates an instance with paragraphs and a corresponding annotation list. Now please help me generate 5 instances.

Specifically, each property measurement should include several roles and their corresponding arguments. The roles are predefined attributes involved in the measurement while the arguments are the specific spans extracted from the paragraph that are corresponding to their roles. Here, we list all the roles as below:

- (1) Substance: [def]
- (2) Property_Name: [def]
- (3) Property_Value: [def]
- (4) Conditions: [def]
- (5) Measurement_Method: [def]

To clearly explain these tasks, we provide the following examples:

Instance 1

Paragraph:

The solubility of compound X in water was determined to be 15 mg/mL at 25°C using the shake-flask method.

Annotation:

Substance: compound X

Property_Name: solubility

Property_Value: 15 mg/mL

Conditions: water, 25°C

Measurement_Method: shake-flask method

...